组会汇报 · 项目导览

Jura Pipeline Map

十个阶段各自回答一个问题，后一个的存在理由是前一个留下的疑点。这份文档说明它们如何衔接、每一步产出什么，以及你现在手上有哪些可以拿去讲的东西。

建模与结果

齐了

动机、方法、主结果、模型选择、稳健性、局限，六项俱全

图表

9 图 + 5 表

全部由精确算术重新生成，数字互相一致

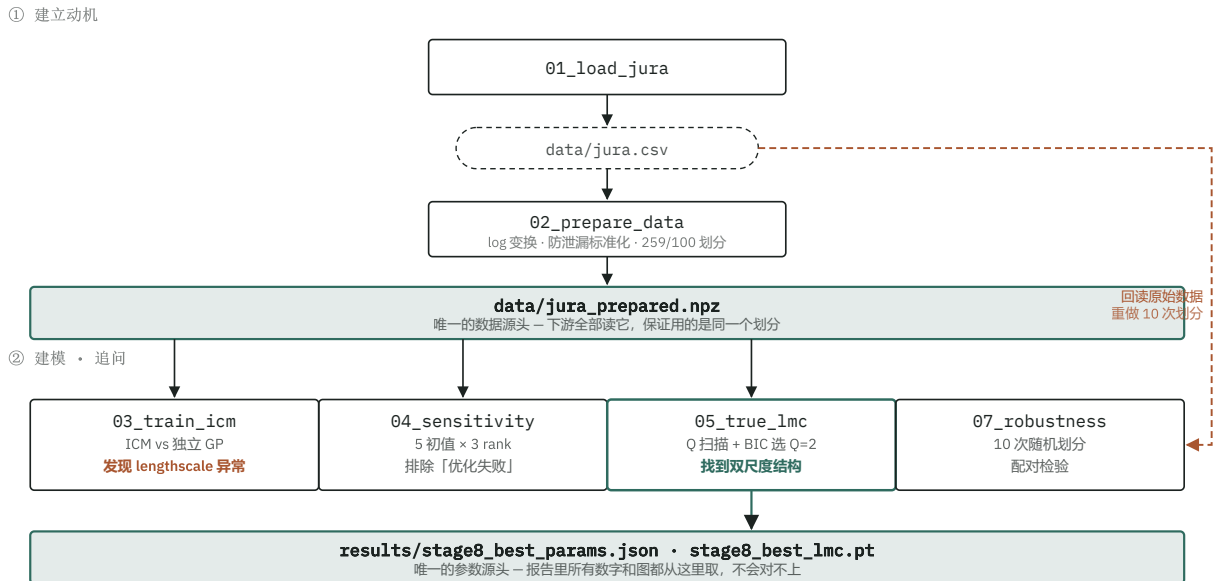
还缺

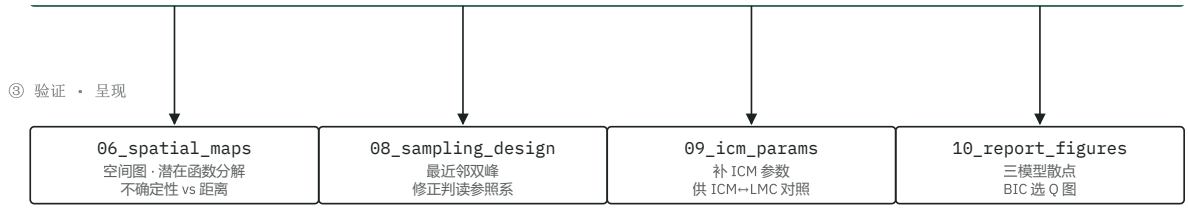
讲稿 / PPT

素材已就位，只差把它们组织成 12–13 页

数据怎么流

两个枢纽文件决定了所有结果的一致性





两个绿色横条是枢纽文件。`02` 产出的 npz 锁定了训练/测试划分，`05` 产出的 json 锁定了模型参数——正因为下游全部从这两个文件取数，图和表的数字才不会互相矛盾。橙色虚线是唯一的例外：`07` 必须绕过 npz 回读原始 csv，因为它要重做十次不同的划分。

四段论证

每一段的存在理由，是上一段留下的疑点

第一段 · 01-02

建立动机

「凭什么认为多输出模型会有帮助？」

算出 log 尺度上三个金属的相关性 **0.654 / 0.686 / 0.699**。这个数字是整个项目的前提——如果它接近 0，后面九个阶段全都没有意义，因为 MOGP 的全部收益都来自"金属之间相关"这一件事。

然后做 heterotopic 划分：Cd 藏 100 个，Ni/Zn 全留。**标准化只用训练观测算均值方差**（Cd 用 259 个而非 359 个），这一步做错就是测试集泄漏。

第二段 · 03

建模，并撞上一个异常

「借用 Ni/Zn 到底能提升多少？」

同样的 100 个测试位置，独立 GP 得 0.9715，ICM 得 **0.7428**，提升 23.5%。而且模型在没看过 EDA 的情况下自己学出了几乎相同的相关结构（0.743 vs 经验的 0.654）。

但学到的 lengthscale 只有 **(0.079, 0.058) km**，远小于网格间距 0.25 km。**这个异常是后面两段的起因。**

第三段 · 04-05

追问异常的来源

「lengthscale 这么短，是数据的性质，还是优化失败了？」

04 排除了优化失败：5 个初值跨 20 倍，全部收敛到同一解，loss 极差 1.8×10^{-11}。顺带证明 rank 对 ICM 恒无影响（极差 2×10^{-14}）。

「那会不会是模型结构限制了它？」

05 证实了这一点：放开成真 LMC 后，模型找到两个并存的尺度——ℓ=0.05 km（相关 0.67，局部污染）和 ℓ=0.43 km（相关 **0.94**，区域母岩背景）。长程结构一直存在，是 ICM 的单一尺度约束把它压掉了。

第四段 · 06–10

验证与呈现

「改善发生在空间上的哪里？是运气吗？判读的参照系对吗？」

06 发现借力只在采样点 0.05 km 内发生——借力半径恰好等于短程分量的 lengthscale。**07** 用 10 次随机划分证明改善不是运气（10/10，$p=6\times10^{-8}$），*同时也证伪了「LMC 优于 ICM」*。**08** 发现之前判读用的"采样间距 0.27 km"是算错的。**09–10** 补齐对照参数并出报告用图。

每个阶段读什么、写什么

绿色行是枢纽文件的产出方

阶段	读	写	回答的问题
01_load_jura	OpenML 41554	jura.csv jura_eda.png	金属之间到底相不相关
02_prepare_data	jura.csv	**jura_prepared.npz**	怎样划分才不泄漏
03_train_icm	npz	（notebook 内）	借力能提升多少
04_sensitivity	npz	sensitivity.csv	是数据性质还是优化失败
05_true_lmc	npz	**stage8_best_params.json** stage8_best_lmc.pt stage8_all_models.csv true_lmc.csv	放开尺度约束会怎样 · Q 取多少
06_spatial_maps	npz + json + pt	stage9_*.png ×3	改善发生在空间的哪里
07_robustness	jura.csv （重做划分）	stage10_robustness.csv stage10_robustness.png	结论是不是运气

08_sampling_design	jura.csv + json	sampling_design.json sampling_design.png	判读的参照系对不对
09_icm_params	npz + all_models.csv	stage8_icm_params.json	ICM 到底学到了什么
10_report_figures	npz + 全部 json/csv/pt	pred_vs_true.png model_selection.png	—

为什么要有两个枢纽

这不是洁癖。之前 `03` 和 `04` 各自训练模型、各自报数字，结果同一个 ICM 在两处出现了不同的 lengthscale 和 RMSE。把参数集中到一个 json 之后，`06` 画的图和报告里的表引用的是同一组数——**这是"图表对不上"这类问题的结构性解决办法**，不是事后核对能替代的。

你的产出

9 张图、5 个结果文件、四条结论

图

文件	讲什么	建议页
jura_eda.png	相关性矩阵 + log 变换（含 Ni 变差的诚实呈现）	2
model_selection.png	BIC/AIC 选 Q + 边际收益 vs 边际代价	5
stage9_latent_decomposition.png	**双尺度分解 — 最有分量的一张**	6
pred_vs_true.png	三模型散点，R^2 = 0.173 / 0.516 / 0.531	7
stage9_spatial_maps.png	空间后验均值 + 不确定性	7
stage9_uncertainty_vs_distance.png	借力半径 = 短程 lengthscale	8
stage10_robustness.png	10 次划分 + 显著性标注	9
sampling_design.png	采样设计双峰	11
true_lmc.png	Q 扫描三联	备用

结果文件

- `stage8_best_params.json` — 选定模型的完整参数，**报告数字的唯一来源**
- `stage8_all_models.csv` — 全部配置，含 k / BIC / AIC
- `stage10_robustness.csv` — 每次划分的三模型指标
- `stage8_icm_params.json` — ICM 参数，用于与 LMC 对照
- `sampling_design.json` — 采样设计的量化描述

四条结论

结论	证据	状态
MOGP 优于单输出 GP	+27.3% ± 4.5%，10/10，$p=6\times10^{-8}$	可讲
模型自主学出的 B ≈ 经验相关性	0.743 / 0.726 / 0.751 vs 0.654 / 0.686 / 0.699	可讲
LMC 恢复出双尺度结构	BIC 与 AIC 一致选 Q=2；长程分量相关 0.88–0.94	可讲
LMC 预测优于 ICM	5/10 划分，p=0.19	不能讲

最后一条必须主动说

单次划分上 LMC 比 ICM 好 1.55%，但这个差距不复现。**与其被问到，不如自己讲出来**——"我们检验了这个差异，它不显著；LMC 的价值在于 ICM 结构上无法表达双尺度分解，而不在预测精度"。这种主动承认比藏起来更能说明工作扎实。

两个会被追问的点

提前准备好答案

「为什么不用普通线性回归？」

实测同点线性回归 `Cd ~ Ni + Zn` 得 RMSE **0.7629**，而 LMC 是 0.7313。也就是说 27% 提升里的大部分来自"用了同点的 Ni/Zn"这件事本身，GP 只额外贡献 **4.15%**。

准备好的回答：GP 相对线性回归仍有实际增益；线性回归给不出校准的不确定性（而空间不确定性图是本研究的核心产出之一）；且线性回归在没有同点 Ni/Zn 的位置完全失效，GP 还能退回空间插值。

> 「你的 **LENGTHSCALE** 是不是崩塌了？」
>
> ICM 学到 0.079 km，确实远小于 0.25 km 的网格间距，但 Jura 是**规则网格 + 嵌套加**